Súboj generácií ResNet:
Vplyv hĺbky na stabilitu učenia

Marko Zeliznak Daniel Szabo Samuel Labanc Samuel Stefan

Neurónové siete 2025/2026
20. apríla 2026

Obsah

1 Formulácia problému **3**

2 Teoretické pozadie **3**
2.1 Problém miznúceho gradientu . . . 3
2.2 Reziduálne prepojenia (Skip Connections) . . . 3
2.3 ResNet-34 vs. ResNet-50 . . . 4
2.4 Adaptácia pre CIFAR-10 . . . 4
2.5 Optimalizátor a plánovač . . . 4

3 Popis datasetu a predspracovanie dát **4**
3.1 CIFAR-10 . . . 4
3.2 Rozdelenie dát . . . 5
3.3 Augmentácia a normalizácia . . . 5

4 Metodológia **5**
4.1 Implementačné rozhodnutia . . . 5
4.2 Spoločné podmienky pre obe architektúry . . . 5
4.3 Sledované metriky . . . 6

5 Návrh experimentov **6**
5.1 Experimenty . . . 6
5.2 Ablačná štúdia: vplyv rýchlosti učenia . . . 6

6 Výsledky **7**
6.1 Porovnanie finálnych výsledkov . . . 7
6.2 Krivky straty a presnosti . . . 7
6.3 Gradient norm . . . 8
6.4 Pamäťová a výpočtová náročnosť . . . 8
6.5 Analýza presnosti podľa tried . . . 9
6.6 Confusion matrix . . . 9

7 Kritická analýza a diskusia **9**
7.1 Prečo ResNet-34 predbehol ResNet-50? . . . 9

7.2 Vplyv rýchlosti učenia (ablačná štúdia) 10
7.3 Pamäť a čas ako praktické kritériá 10
7.4 Analýza chýb — ktoré triedy sú najťažšie? 10
7.5 Stabilita učenia a skip connections 11

8 Obmedzenia a možnosti ďalšej práce **11**

9 Prínosy jednotlivých členov tímu **11**

10 Záver **12**

1 Formulácia problému

Tento projekt sa zameriava na porovnanie dvoch reziduálnych konvolučných neurónových sietí — **ResNet-34** a **ResNet-50** — pri klasifikácii obrazov na datasete CIFAR-10. Centrálna výskumná otázka znie:

> *Ako zmena hĺbky siete (ResNet-34 vs. ResNet-50) ovplyvňuje stabilitu učenia, rýchlosť konvergencie, pamäťovú náročnosť a dosiahnutú presnosť klasifikácie?*

Kľúčová motivácia vychádza z paradoxu hlbokých sietí: intuitívne by sme očakávali, že hlbšia sieť s väčším počtom vrstiev dosiahne lepšie výsledky. V praxi však samotné pridávanie vrstiev spôsobuje problémy (miznúci/explodujúci gradient, degradácia presnosti). Architektúra ResNet tento paradox adresuje reziduálnymi prepojeniami (*skip connections*). Zaujíma nás, či prechod od ResNet-34 k ResNet-50 prináša merateľný prínos, alebo či zvýšená výpočtová náročnosť nie je oprávnená pri jednoduchšom datasete (CIFAR-10).

Sekundárnou výskumnou otázkou je **ablačná štúdia vplyvu rýchlosti učenia** (learning rate): porovnávame hodnoty $lr = 10^{-3}$ a $lr = 10^{-4}$ pre obe architektúry, čím sledujeme interakciu hĺbky siete s voľbou hyperparametru.

2 Teoretické pozadie

2.1 Problém miznúceho gradientu

Pri spätnom šírení chyby (*backpropagation*) sa gradient znásobuje Jacobiánom každej vrstvy. Ak sú tieto hodnoty menšie ako 1, gradient exponenciálne klesá smerom k vstupným vrstvám — hovoríme o *miznúcom gradiente* [2]. Výsledkom je, že skoré vrstvy sa učia extrémne pomaly, čím celkové trénovanie stagnuje. Opačný jav, *explodujúci gradient*, nastáva keď sú hodnoty Jacobiánov väčšie ako 1.

2.2 Reziduálne prepojenia (Skip Connections)

Architektúra ResNet [1] rieši oba problémy zavedením reziduálneho bloku:

$$\mathbf{y} = \mathcal{F}(\mathbf{x}, \{W_i\}) + \mathbf{x} \tag{1}$$

kde $\mathcal{F}(\mathbf{x})$ je reziduálna funkcia (niekoľko konvolučných vrstiev) a $\mathbf{x}$ je vstup prenesený priamo cez skok (*identity shortcut connection*). Tento tvar má niekoľko dôsledkov:

- Gradient môže plynúť priamo cez skratku bez útlmu.
- Sieť sa môže naučiť iba reziduálnu diferenciu oproti identite — jednoduchšia úloha.
- Hlbšie siete prestávajú degradovať: pridanie vrstiev nemôže zhoršiť výsledky, lebo v najhoršom prípade sa naučia nulový reziduál ($\mathcal{F} = 0$).

2.3 ResNet-34 vs. ResNet-50

ResNet-34 používa *základné reziduálne bloky* (*basic blocks*) tvorené dvoma konvolúciami 3×3 za sebou:

$$\text{BasicBlock}: \quad \text{Conv}_{3\times3} \to \text{BN} \to \text{ReLU} \to \text{Conv}_{3\times3} \to \text{BN} \to (+\,x) \to \text{ReLU} \tag{2}$$

ResNet-50 nahradí základné bloky *bottleneck blokmi*, ktoré znižujú dimenziu príznakových máp pred drahšou 3×3 konvolúciou a potom ju opäť rozširujú:

$$\text{Bottleneck}: \quad \text{Conv}_{1\times1} \to \text{BN} \to \text{ReLU} \to \text{Conv}_{3\times3} \to \text{BN} \to \text{ReLU} \to \text{Conv}_{1\times1} \to \text{BN} \to (+\,x) \to \text{R} \tag{3}$$

Bottleneck bloky umožňujú väčšiu hĺbku bez dramatického nárastu FLOP-ov na blok, avšak zvyšujú celkové parametre a pamäťovú náročnosť siete.

2.4 Adaptácia pre CIFAR-10

Originálny ResNet bol navrhnutý pre ImageNet (obrázky 224×224). Pri priamom použití na CIFAR-10 (32×32) by prvá konvolúcia 7×7, stride 2 s následným maxpoolingom (stride 2) zredukovala priestorové rozlíšenie na 8×8 ešte pred prvým reziduálnym blokom, čím by sa stratila podstatná časť informácie. Preto sme predradenosť adaptovali:

- `conv1`: 7×7, stride 2 $\to$ 3×3, stride 1 (zachováme rozlíšenie)
- `maxpool`: nahradená identitou (žiadne downsampling)

Táto adaptácia je štandardným prístupom pre CIFAR-10 [1].

2.5 Optimalizátor a plánovač

Použili sme **Adam** [3] s reguláciou váh (*weight decay* 10^{-4}), pretože Adam adaptívne škáluje rýchlosť učenia pre každý parameter. Ako plánovač sme zvolili **CosineAnnealingLR** [5]:

$$\eta_t = \eta_{\min} + \frac{1}{2}(\eta_{\max} - \eta_{\min})\left(1 + \cos\left(\frac{t \cdot \pi}{T_{\max}}\right)\right) \tag{4}$$

kde $T_{\max}$ je celkový počet epoch. Tento plán hladko znižuje rýchlosť učenia a zabraňuje osciláciám na konci trénovania.

3 Popis datasetu a predspracovanie dát

3.1 CIFAR-10

CIFAR-10 [4] je štandardný benchmark pre klasifikáciu obrazov:

- 60 000 farebných obrázkov (32×32 pixelov, 3 kanály)
- 10 tried: *airplane, automobile, bird, cat, deer, dog, frog, horse, ship, truck*
- 6 000 obrázkov na triedu (rovnomerné zastúpenie)
- Oficiálne rozdelenie: 50 000 trénovacích a 10 000 testovacích vzoriek

3.2 Rozdelenie dát

Aby sme zabránili úniku informácií (*data leakage*), testovacia sada zostala úplne oddelená počas celého trénovania. Validačnú sadu sme vyčlenili z trénovacej množiny (10 % = 5 000 vzoriek), pričom rozdelenie bolo deterministické (seed = 42) pre plnú reprodukovateľnosť.

Tabuľka 1: Rozdelenie datasetu CIFAR-10

Množina	**Počet vzoriek**	**Účel**
Trénovacia	45 000	tréning váh
Validačná	5 000	ladenie hyperparametrov, early stopping
Testovacia	10 000	finálna evaluácia (použitá iba raz)

3.3 Augmentácia a normalizácia

Pri trénovaní sme aplikovali štandardnú augmentáciu:

- `RandomCrop(32, padding=4)`: náhodné orezanie so zapadovaním
- `RandomHorizontalFlip()`: náhodné horizontálne zrkadlenie

Pri validácii a testovaní sme augmentáciu vypli.

Všetky obrázky sme normalizovali hodnotami odvodenými z trénovacej sady CIFAR-10:

$$\mu = (0.4914,\ 0.4822,\ 0.4465), \qquad \sigma = (0.2470,\ 0.2435,\ 0.2616) \tag{5}$$

4 Metodológia

4.1 Implementačné rozhodnutia

Modely boli implementované pomocou knižnice `torchvision.models` (PyTorch) — bez trénovania od nuly z architektúry vlastnej implementácie, čo redukuje implementačné chyby. Namiesto transfer learningu (ImageNet váhy) sme použili **náhodne inicializované váhy** (Kaiming normal), pretože cieľom je porovnanie architektúr, nie transfer learningu.

4.2 Spoločné podmienky pre obe architektúry

Aby bolo porovnanie spravodlivé, obe siete boli trénované za identických podmienok:

Tabuľka 2: Konfigurácia trénovania (rovnaká pre oba modely)

Hyperparameter	**Hodnota**
Počet epoch	20
Batch size	128
Weight decay	10^{-4}
Optimalizátor	Adam
Plánovač LR	CosineAnnealingLR ($\eta_{\min} = 0$)
Seed	42
Augmentácia	RandomCrop + RandomHorizontalFlip

4.3 Sledované metriky

Počas každej epochy sme zaznamenávali:

- **Train/Val loss** (cross-entropy)
- **Train/Val accuracy** (% správne klasifikovaných)
- **Gradient norm** (priemerná L2-norma gradientov cez všetky batchy)
- **Čas epochy** (sekundy)
- **Peak GPU pamäť** (MB)

Tieto metriky umožňujú nielen porovnanie finálnej presnosti, ale aj analýzu dynamiky trénovania — dôležitého aspektu pri skúmaní vplyvu hĺbky na stabilitu.

5 Návrh experimentov

5.1 Experimenty

Realizovali sme 4 experimenty usporiadané v mriežke 2×2:

Tabuľka 3: Prehľad experimentov

ID	**Model**	**LR**	**Kód**
E1	ResNet-34	10^{-3}	`resnet34_lr1e3`
E2	ResNet-34	10^{-4}	`resnet34_lr1e4`
E3	ResNet-50	10^{-3}	`resnet50_lr1e3`
E4	ResNet-50	10^{-4}	`resnet50_lr1e4`

5.2 Ablačná štúdia: vplyv rýchlosti učenia

Porovnanie E1 vs. E2 (resp. E3 vs. E4) tvorí **kontrolovaný experiment** (ablation study): meníme iba jeden hyperparameter (learning rate), zatiaľ čo všetky ostatné podmienky zostávajú rovnaké. Cieľom je oddeliť vplyv architektúry od vplyvu rýchlosti učenia.

Voľba hodnôt 10^{-3} a 10^{-4} je motivovaná tým, že pri Adame s CosineAnnealingLR sú to reprezentatívne zástupcovia „rýchlehoä „pomaléhoüčenia na tejto škále.

6 Výsledky

6.1 Porovnanie finálnych výsledkov

Tabuľka 4: Súhrnné výsledky všetkých experimentov

Experiment	Model	LR	Best Val Acc	Test Acc	Pamäť [MB]	Čas/ep. [s]
E1	ResNet-34	10^{-3}	92.54 %	**91.69 %**	1 338.6	≈ 45
E2	ResNet-34	10^{-4}	85.84 %	85.19 %	1 336.6	≈ 45
E3	ResNet-50	10^{-3}	92.14 %	90.96 %	3 526.5	≈ 72
E4	ResNet-50	10^{-4}	77.02 %	77.25 %	3 525.7	≈ 72

Najlepší výsledok dosiahol **ResNet-34 s lr** $= 10^{-3}$ (test acc 91.69 %). ResNet-50 s rovnakou rýchlosťou učenia zaostal o 0.73 percentuálneho bodu. Výraznejší rozdiel nastáva pri nižšom learning rate — ResNet-50 s $lr = 10^{-4}$ dosiahol iba 77.25 %, čo je o 7.94 p.b. menej ako ResNet-34 pri rovnakej LR.

6.2 Krivky straty a presnosti

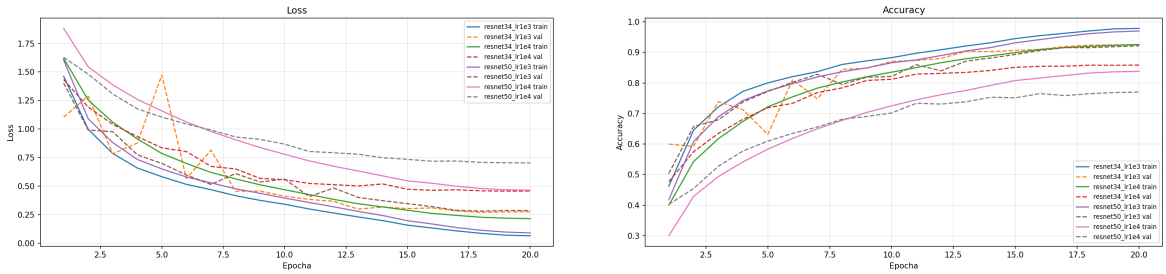

(a) Trénovacia strata (train loss)

(b) Trénovacia presnosť (train accuracy)

Obr. 1: Porovnanie priebehu trénovania pre všetky 4 experimenty (20 epoch)

Z obrázku 1 je zrejmé:

- E1 a E3 ($lr = 10^{-3}$) konvergujú rýchlo a stabilne.
- E2 ($lr = 10^{-4}$, ResNet-34) konverguje pomaly ale monotónne.
- E4 ($lr = 10^{-4}$, ResNet-50) konverguje výrazne pomalšie — po 20 epochách ešte stále nedosiahol plochu konvergencie.

6.3 Gradient norm

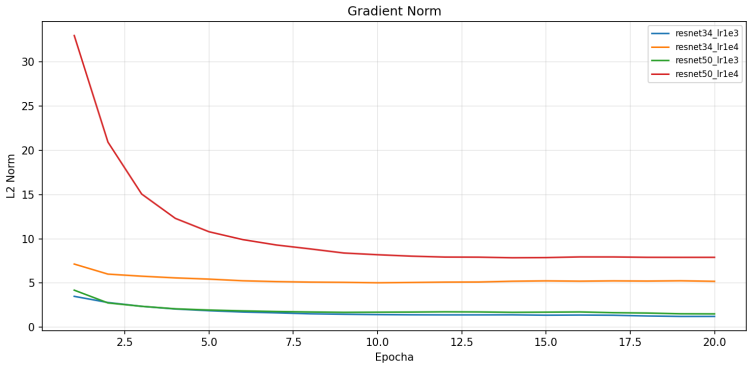

Obr. 2: Priebeh gradient normy počas trénovania

Gradient norma je kľúčovým indikátorom stability trénovania. Z obrázku 2 vidíme dramatický rozdiel medzi experimentmi:

Tabuľka 5: Gradient norma — porovnanie prvej a poslednej epochy

Experiment	**Model / LR**	**Ep. 1**	**Ep. 20**
E1	ResNet-34, 10^{-3}	3.49	1.23
E2	ResNet-34, 10^{-4}	7.14	5.19
E3	ResNet-50, 10^{-3}	4.19	1.51
E4	ResNet-50, 10^{-4}	**32.95**	7.90

E4 začínal s gradient normou takmer **33** — tento vysoký počiatočný gradient signalizuje nestabilnú inicializáciu v spojení s nízkym LR: sieť reaguje na chybu veľkými krokmi gradientu, avšak kvôli malej LR ich využíva neefektívne.

6.4 Pamäťová a výpočtová náročnosť

Tabuľka 6: Pamäťová a časová náročnosť

Architektúra	**Peak GPU pamäť**	**Priemerný čas epochy**
ResNet-34	1 338 MB	$\approx$ 45 s
ResNet-50	3 526 MB	$\approx$ 72 s
Pomer (50/34)	**2.63**$\times$	**1.60**$\times$

ResNet-50 spotreboval viac ako 2.6-násobok GPU pamäte a 1.6-násobok času oproti ResNet-34.

6.5 Analýza presnosti podľa tried

Tabuľka 7: Presnosť klasifikácie podľa tried — testovacie výsledky E1 a E3

Trieda	**RN34 správne**	**RN34 acc**	**RN50 správne**	**RN50 acc**
cat	804	80.4 %	795	79.5 %
bird	872	87.2 %	867	86.7 %
dog	880	88.0 %	869	86.9 %
airplane	922	92.2 %	921	92.1 %
horse	931	93.1 %	939	93.9 %
deer	935	93.5 %	906	90.6 %
frog	950	95.0 %	941	94.1 %
truck	951	95.1 %	945	94.5 %
ship	955	95.5 %	948	94.8 %
automobile	969	96.9 %	965	96.5 %
Celkovo	**9 169**	**91.69 %**	**9 096**	**90.96 %**

6.6 Confusion matrix

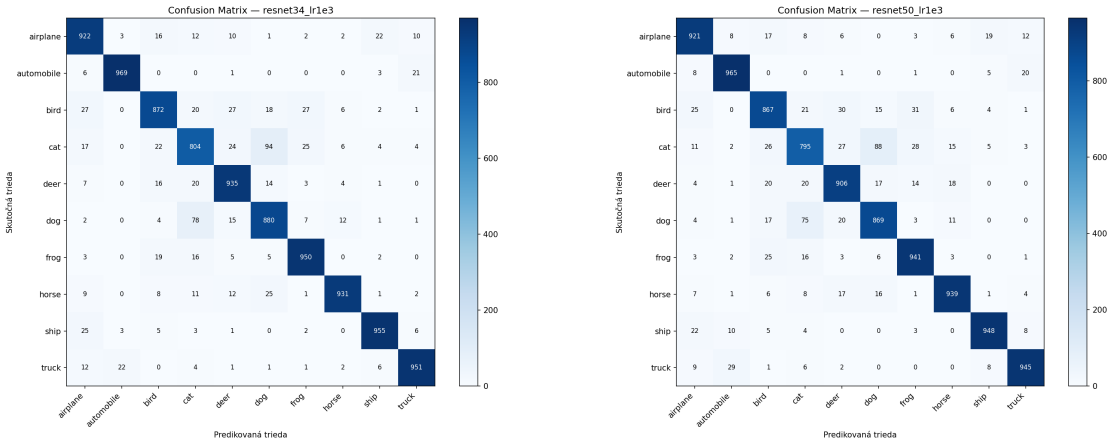

(a) ResNet-34, $lr = 10^{-3}$

(b) ResNet-50, $lr = 10^{-3}$

Obr. 3: Confusion matrix na testovacej sade (E1 a E3)

7 Kritická analýza a diskusia

7.1 Prečo ResNet-34 predbehol ResNet-50?

Výsledok môže pôsobiť prekvapivo — menej hlboká sieť dosiahla lepšiu presnosť. Dôvody sú nasledovné:

1. Overfitting vs. underfitting. CIFAR-10 je relatívne jednoduchý dataset (32×32 px, 10 tried). ResNet-50 má výrazne viac parametrov (bottleneck bloky výrazne zvyšujú kapacitu). Pri krátkom trénovaní (20 epoch) väčšia kapacita nie je plne využitá a model sklouzáva do čiastočného overfittingu.

2. Nedostatočný tréning pre väčší model. ResNet-50 s $lr = 10^{-3}$ ešte po 20 epochách nebol plne konvergovaný (train_acc = 96.98 %, zatiaľ čo ResNet-34 dosiahol 97.84 %). Väčší model potrebuje viac epoch alebo vyšší LR, aby plne využil svoju kapacitu.

3. Adaptácia architektúry. Obe siete boli adaptované pre CIFAR-10 (zmena conv1 a odstránenie maxpool). Táto adaptácia sa mierne odlišuje od pôvodného dizajnu bottleneck blokov, čo môže nepriaznivo ovplyvniť ResNet-50 viac ako ResNet-34.

7.2 Vplyv rýchlosti učenia (ablačná štúdia)

Výsledky ablačnej štúdie odhalili zaujímavú asymetriu:

- **ResNet-34**: pokles z $lr = 10^{-3}$ na 10^{-4} spôsobil pokles test acc o 6.50 p.b. (z 91.69 % na 85.19 %).
- **ResNet-50**: rovnaký pokles LR spôsobil pokles o 13.71 p.b. (z 90.96 % na 77.25 %).

Väčší model je teda **citlivejší na voľbu rýchlosti učenia**. Vysvetlenie: pri $lr = 10^{-4}$ s CosineAnnealingLR je počiatočná rýchlosť učenia príliš malá na to, aby sa hlbší model dostal z oblasti slabej počiatočnej inicializácie. Gradient norma E4 (32.95 v 1. epoche) potvrdzuje, že sieť sa ocitla v oblasti ostrého gradientu, avšak LR nestačilo na opustenie tejto oblasti.

7.3 Pamäť a čas ako praktické kritériá

Z praktického pohľadu je pomer výkon/zdroje rozhodujúci:

- ResNet-50 spotreboval 2.63× viac pamäte za cenu len 0.73 p.b. lepšieho výkonu v najlepšom prípade (a dokonca horšieho s rovnakou LR).
- Na CIFAR-10 je ResNet-34 **pareto-optimálnou voľbou**: nižšia pamäť, kratší čas trénovania, mierne lepšia presnosť.
- Na náročnejšom datasete (ImageNet, CIFAR-100) by porovnanie mohlo byť odlišné, keďže väčšia kapacita ResNet-50 by mala väčší priestor sa prejaviť.

7.4 Analýza chýb — ktoré triedy sú najťažšie?

Zo všetkých experimentov konzistentne vyplýva, že najťažšie triedy sú:

1. **cat** (80.4 % a 79.5 %) — najčastejšie zamieňaná s dog
2. **bird** (87.2 % a 86.7 %)
3. **dog** (88.0 % a 86.9 %)

Tieto triedy zdieľajú vizuálne rysy: cat a dog majú podobné tvary tela a srsti, bird môže byť zamieňaný s letúchom (airplane) pri nízkom rozlíšení. Najľahšie triedy sú **automobile, ship, truck** — vozidlá majú charakteristické geometrické tvary, ktoré sú jednoznačné aj na 32×32 px obrázkoch.

7.5 Stabilita učenia a skip connections

Gradient norma E1 a E3 klesá monotónne od ≈ 3.5 (resp. 4.2) na ≈ 1.2 (resp. 1.5), čo svedčí o stabilnom toku gradientu — priamym dôsledkom reziduálnych prepojení. V experimente E4 vysoká počiatočná gradient norma (32.95) ukazuje, že bez správnej kalibrácie LR môže aj sieť so skip connections trpieť nestabilitou.

8 Obmedzenia a možnosti ďalšej práce

Obmedzenia tejto štúdie:

- **Krátke trénovanie (20 epoch):** Oba modely s $lr = 10^{-3}$ ešte nedosiahli plnú konvergenciu; dlhší tréning by mohol zmeniť relatívne porovnanie.
- **Iba dve hodnoty LR:** Grid search alebo Bayesian optimalizácia by odhalili optimálne LR pre každú architektúru osobitne.
- **Jednoduchý dataset:** CIFAR-10 nemusí plne využiť kapacitu ResNet-50; experimenty na CIFAR-100 alebo Tiny ImageNet by boli informatívnejšie.
- **Bez transfer learningu:** Porovnanie „od nuly"je spravodlivé pre architekturálnu analýzu, ale pre praktické nasadenie by bol transfer learning relevantnejší.

Možnosti ďalšej práce:

- Predĺžiť tréning na 100+ epoch s warm-up fázou.
- Porovnať s ResNet-101 a ResNet-152 pre širší pohľad na škálovanie.
- Pridať label smoothing alebo mixup augmentáciu.
- Vizualizovať aktivačné mapy pomocou Grad-CAM pre interpretovateľnosť.
- Otestovať na CIFAR-100 pre porovnanie pri väčšom počte tried.

9 Prínosy jednotlivých členov tímu

- **Marko Zeliznak** — návrh experimentálnej metodológie, konfigurácia hyperparametrov, implementácia tréningového pipeline, trénovanie modelov, analýza chýb, vypracovanie reportu.
- **Daniel Szabo** — implementácia a ladenie modelov ResNet-34 a ResNet-50, príprava dátového pipeline a augmentácií.
- **Samuel Labanc** — vyhodnotenie výsledkov, tvorba grafov a vizualizácií, analýza pamäťovej a výpočtovej náročnosti.
- **Samuel Stefan** — analýza chýb klasifikácie (confusion matrix, per-class accuracy), interpretácia výsledkov a diskusia obmedzení.

10 Záver

Táto štúdia porovnávala ResNet-34 a ResNet-50 na datasete CIFAR-10 pri dvoch konfiguráciách rýchlosti učenia. Hlavné zistenia:

1. **ResNet-34 ($lr = 10^{-3}$) dosiahol najlepší test accuracy (91.69 %)** napriek menšej hĺbke, čo demonštruje, že väčšia kapacita modelu nezaručuje lepšie výsledky pri obmedzenom trénovaní na jednoduchom datasete.
2. **Pamäťová a výpočtová náročnosť ResNet-50 je výrazne vyššia** (2.63× viac pamäte, 1.60× dlhší čas epochy) bez zodpovedajúceho prínosu v presnosti.
3. **ResNet-50 je citlivejší na voľbu LR:** pokles z 10^{-3} na 10^{-4} spôsobil stratu 13.71 p.b. vs. 6.50 p.b. pri ResNet-34.
4. **Skip connections stabilizujú gradient flow:** gradient normy klesajú monotónne u E1 a E3, čo potvrdzuje teóriu o benefitoch reziduálnych prepojení.
5. **Najťažšie triedy sú cat, dog, bird** — konzistentne naprieč všetkými modelmi, čo odráža inherentnú vizuálnu podobnosť týchto tried na 32×32 px.

Záverom možno konštatovať, že pre jednoduchý experiment na CIFAR-10 je **ResNet-34 praktickejšou voľbou**: poskytuje porovnateľnú presnosť s výrazne nižšou pamäťovou a výpočtovou záťažou. Hlbšie architektúry ako ResNet-50 preukážu svoju hodnotu na náročnejších úlohách, kde väčšia kapacita a dlhšie trénovanie sú oprávnené.

Literatúra

[1] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778, 2016.

[2] Sepp Hochreiter. Untersuchungen zu dynamischen neuronalen netzen. 1991.

[3] Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization. *International Conference on Learning Representations (ICLR)*, 2015.

[4] Alex Krizhevsky. Learning multiple layers of features from tiny images. Technical report, University of Toronto, 2009.

[5] Ilya Loshchilov and Frank Hutter. Sgdr: Stochastic gradient descent with warm restarts. *International Conference on Learning Representations (ICLR)*, 2017.